

UNIVERSIDADE ESTADUAL DE CAMPINAS

Prova de Ea616

Aluno: Bruno Eduardo Freire e Silva

RA:195052

b195052@dac.unicamp.com

Campinas, SP
2020

1-Introdução:

Esse trabalho tem por objetivo tentar explicar a atual propagação do coronavírus através de um modelamento epidêmico do tipo SIR.

Neste modelo observamos a interação entre o número de infectados $i(t)$, o número de pessoas saudáveis e o número de pessoas recuperadas / mortas $r(t)$ durante um determinado período. As equações que regem tal interação são dadas por:

$$\frac{dI}{dt} = \frac{\gamma IS}{M} - \alpha I$$

$$\frac{dS}{dt} = - \frac{\gamma IS}{M} \quad \text{eqs 1,2, 3 e 4}$$

$$\frac{dR}{dt} = \alpha I$$

$$R + I + S = M$$

Onde I é o número de infectados, S é o número de pessoas saudáveis, R é o número de pessoas recuperadas/mortas, γ é a taxa de transmissão (quantas pessoas, em média, um infectado infecta), α é taxa de recuperação e, por fim, M que é a população total (no caso do Brasil, 210 milhões de pessoas).

Dessas equações também podemos calcular o número acumulado de infectados $a(t)$, que é dado pela seguinte equação:

$$\frac{dA}{dt} = \frac{\gamma IS}{M} \quad \text{eq 5}$$

Como o objetivo deste trabalho é explicar o atual cenário de infecção, temos portanto que achar os parâmetros (I inicial, S inicial, A inicial, γ e α) que quando postos sobre tais equações, nos devolvem um curva parecida com a curva de infecção real. Para isso vamos escrever um código que as calcula computacionalmente.

É mais fácil trabalhar com o modelamento SIR discretizado, por isso vamos aplicar a transformação de Euler as equações 1,2 e 4 e teremos as seguintes equações:

$$\begin{aligned} s(k+1) &= s(k) - \frac{\gamma i(k)s(k)}{M} \\ i(k+1) &= (1 - \alpha)i(k) + \frac{\gamma i(k)s(k)}{M} \\ a(k+1) &= a(k) + \frac{\gamma i(k)s(k)}{M} \end{aligned} \quad \text{eq 6, 7, 8}$$

Tendo as equações acima, os dados reais de $a(k)$ e um bom algoritmo de otimização, podemos achar os parâmetros que mais explicam o atual cenário de infecção.

2-Objetivo:

O objetivo desse trabalho é escrever um código python que faça o processo de otimização de hiperparâmetros e com esses hiperparâmetros poder discutir o

atual cenário de infecção no Brasil. Além de claro, poder discutir a qualidade do modelamento.

3-Algoritmo de otimização:

Pretendemos achar os parametros otimos utilizando a função `gp_minimize` da biblioteca de otimização `scikit-optimize`, essa biblioteca utiliza-se do processo de otimização com base no erro mínimo quadrático, ou seja, ela tenta achar os valores de α , γ , i_0 , s_0 e a_0 para os quais minimizam a somatória das diferenças entre o y observado e o y calculado elevados ao quadrado:

$$f(\alpha, \gamma) \text{ t.q. } \min \sum_{t=0}^{t=n} [f(\alpha, \gamma) - f_{obs}]^2$$

O algoritmo será:

```
import pandas as pd
import numpy as np
from sklearn.metrics import mean_absolute_error,
mean_squared_error
from skopt import gp_minimize
def sir_model(length, a0, s0, i0, gama, alpha):
    M=210147125
    ak = a0
    sk = s0
    ik = i0
    acumulate = [a0]
    for i in range(1,length):
        skplus1 = sk - (gama * (sk / M) * ik)
        ikplus1 = ik + (gama * (sk / M) * ik) - (alpha * ik)
        akplus1 = ak + (gama * (sk / M) * ik)
        ak = akplus1
        sk = skplus1
        ik = ikplus1
        acumulate.append(ak)

    return np.array(acumulate)
# load data
filepath = '/content/drive/My
Drive/projeto_ea_616/HIST_PAINEL_COVIDBR_24jun2020.xlsx'
data = pd.read_excel(filepath)
# preprocessing data
```

```

ydata = data[data.regiao ==
'Brasil'].casosAcumulado.to_numpy()[1:]

global ydata
def func_to_minimize(params):
    ycalc = sir_model(120, params[0], params[1],
                      params[2], params[3], params[4])
    MAE = mean_absolute_error(ydata, ycalc)
    return MAE ** (1/2)
space = [(400, 495), (150000000, 1835793857), (400, 495), (0.30,
0.32), (0.20, 0.24)]
y = gp_minimize(func_to_minimize, space, n_calls=100,
random_state=1234, n_random_starts=20, verbose=True)

```

obs : A variável y contém um método x que retorna os parâmetros ótimos

3.2- Como o algoritmo gp_minimize funciona:

Este algoritmo funciona com base na busca bayesiana de hiperparâmetros. De início criamos vários conjuntos randômicos de parâmetros e para cada conjunto calculamos o erro médio absoluto , com base nesses resultados fazemos um processo gaussiano sobre essas métricas, i.e procuramos por regiões onde mais provavelmente acharemos os melhores parâmetros.

Obs: O erro médio absoluto é gerado pela função python func_to_minimize, que calcula essa métrica usando a função sir_model, ou seja, estamos otimizando os parâmetros do modelo SIR.

3.3- Como foi feito o processo de achar hiperparâmetros:

Como o modelo SIR é extremamente não linear, o processo de busca de hiperparâmetros não pode ser feito de uma vez só, pelo menos com essa metodologia de busca. Então, para conseguir melhores resultados devemos repetir diversas vezes o processo de otimização, e em cada vez, mudar o intervalo em que vamos buscar cada hiperparâmetro.

No meu caso, eu separei a busca em 2 fases, a primeira fase eu tentei achar o melhor intervalo para os parâmetros gama e alfa, enquanto os parâmetros i0, s0 e a0 eu fixei em 1, M-1 e 1. Encontrado os melhores intervalos de gama e alfa, irei procurar os melhores intervalos para i0, s0 e a0.

4- Resultados e discussões:

Nas primeiras iterações percebi que o modelo se comporta muito mal quando definimos um intervalo muito grande para os parâmetros, veja:

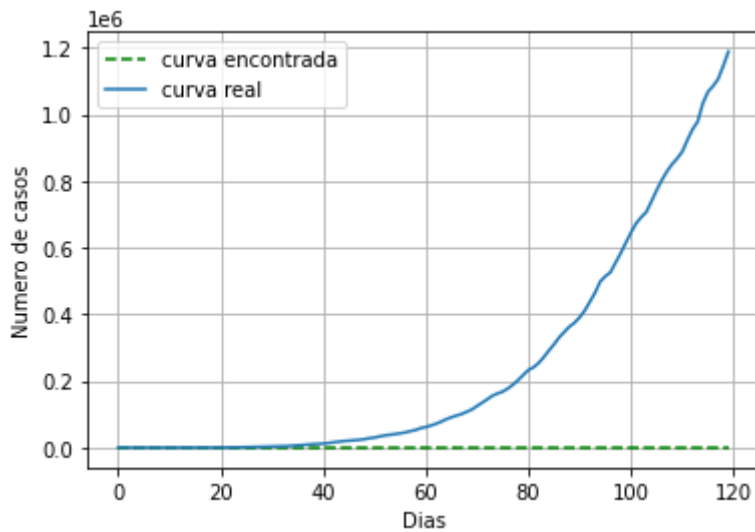


Figura 1: Parâmetros ótimos: $a_0 = 1944$, $s_0 = 2537285$, $i_0 = 105$, $\gamma = 0$, $\alpha = 1$; Métricas: Mean_absolute_error = 242064

Percebemos que a curva calculada não acompanha em nada a curva real. Vendo isso resolvi procurar por intervalos mais restritos, depois de várias variações, percebi que os melhores valores de γ e α estavam em (0.30, 0.32) para γ e (0.20, 0.24) para α :




Figura 2: Parâmetros ótimos: $a_0 = 996$, $s_0 = 171866397$, $i_0 = 1225$, $\gamma = 0.3154$, $\alpha = 0.21721339542755375$; Métricas: Mean_absolute_error = 76508

Agora o trabalho era encontrar os parâmetros i_0 , s_0 e a_0 . Depois de vários testes chegamos aos valores ótimos de $i_0=695$, $s_0=183793857$, $a_0=697$, $\gamma=0.3092$ e $\alpha=0.2187$ e para esse conjunto de parâmetros achamos um erro absoluto médio de 29929, aproximadamente:




Figura 3: Parâmetros ótimos: $a_0 = 695$, $s_0 = 183793857$, $i_0 = 697$, $\gamma = 0.3092$, $\alpha = 0.2188$; Métricas: Mean_absolute_error = 29929.

Como vemos no gráfico acima, conseguimos aproximar bem a curva real da curva calculada e com isso tirar algumas conclusões do comportamento desta. Podemos, por exemplo, discutir o significado dos parâmetros alfa e gama, uma taxa de recuperação de 0.2187 nos indica que o período de infecção Θ ($\Theta = \frac{1}{\alpha}$) é de aproximadamente 4.57 dias (na literatura encontramos que tal valor vale 5.2 [1]). Já uma taxa de transmissão de 0.3092 nos indica que, em média, uma pessoa infectada transmite o vírus para 1.41 pessoas ($N_{\text{pessoas}} = \frac{\gamma}{\alpha}$) (na literatura vemos que esse valor é aproximadamente 3.2 para o Brasil)

Com relação a predição do comportamento futuro, não posso afirmar nada numericamente, a única certeza é que em um curto prazo de tempo a curva de infectados ficará maior, numa tendência quase exponencial. Essa tendência é fruto de uma série de fatores comportamentais como a negação da gravidade da doença, não testagem em massa da população, medidas de isolamento pouco efetivas... Todos esses fatores influenciam no comportamento da curva e isso o modelo SIR não consegue explicar adequadamente.

5- Bibliografia:

[1] DRA .DANIELA BUSKE. A evolução do epidêmica do covid-19 ? modelo sir. , 2020.

Disponível em:

<<http://https://wp.ufpel.edu.br/fentransporte/2020/04/09/a-evolucao-epidematica-do-covid-19-mo-del-sir/>>. Acesso em: 26 jun. 2020.